S_01 Descriptive Statistics

Statistical Analysis

References

Text and figures from the DATAtab site (https://datatab.net/) and the book "Statistics made easy" published by DATAtab.

DATAtab


Statistics Page from Scribbr site (https://www.scribbr.com/category/statistics/)




LLM: ChatGPT, Claude 3

Population and Sample

- Population (모집단)
 - ㅇ 통계의 대상이 되는 모든 개체를 포함하는 집단
 - o ex) 대한민국 사람 전체, 서울시민전체, 대전소 재 21세 여성 전체, ...
 - o Population에 속한 전체 개체의 data를 얻기는 사실상 불가
- Sample (표본)
 - Population 으로부터 sampling된 Sample 을 대 상으로 한 통계가 흔히 사용됨
 - o Sample은 sampling된 개체들의 집단을 의미하며, "Sample Set" 이라 부르지 않음



Descriptive vs Inferential Statistics



- Descriptive statistics (기술 통계): Sample의 통계를 describe 하기 위해 사용
 o ex) 전국민 평균 수면 시간
- Inferential statistics (추론 통계): Sample의 통계로부터 Population의 통계를 추론 (inference) 해 내기 위해 사용

Types of Variables (by characteristics of value)

- Categorical Variables
 - o Nominal: value들을 순서 없이 구분만 가능
 - o Ordinal: value들의 순서 있음
- Quantitative Variables (= Metric Variables)
 - o Continuous: value domain real number
 - o Discrete: value □ domain □ integer

Nominal Variables

- Operations: equal, unequal
- No ranking and order
- ex) Binary (dichotomous) value가 두 개 뿐인 경우

Examples:		Preferred
Gender	Marital status	newspaper:
1 = male	single	The Washington Post
2 = female	married	The New York Times
	divorced	USA Today
	widowed	

Ordinal Variables

- Operations: equal, unequal, greater, smaller
- Ranking (hierarchy) exists

Examples:	The government is doing a good
Frequency of television:	job:
1 = daily	1 = agree with
2 = several times a week	2 = undecided
3 = less frequently	3 = disagree with
4 = never	

But no exact distance between different values

Quantitative (Metric) Variables

- Equal, unequal, greater, smaller, difference, sum
- 즉, value들 간의 수치적인 차이를 정확히 계산 가능

Examples:

Income	Weight	Age	Electricity
1820 \$	81 kg	18 years	consumption
3200 \$	70 kg	27 years	520 kWh
800 \$	68 kg	64 years	470 kWh
			340 kWh
•••			

Level of Measurement

Nominal

Characteristics can be distinguished.

A D

Ordinal

Characteristics can be sorted.

Metric

Distances between the values can be calculated.

Metric Variable – Ratio Scale

- Ratio Scale (비율척도)
- Data value들 간 가치의 비율이 의미가 있음
- 절대 영점 (absolute zero) 이 반드시 존재
- ex)
 - ㅇ 마라톤 기록: 1등의 기록이 꼴찌의 기록보다 두배 빠르다. (절대 영점: 마라톤 시작 시간)
 - o 10kg 은 20kg 무게의 1/2 이다. (절대 영점: 0kg)






Metric Variable – Interval Scale

- Interval Scale (간격 척도)
- Data value들 간의 차이만 계산 가능
- 절대 영점 (absolute zero) 이 없음, 비율 계산 불가
- ex)
 - o 마라톤 시작 때 눌렀던 스톱워치를 분실한 경우
 - 선두와 2등 간의 시간 간격 측정만 가능
 - 선두가 2등보다 두배 빠르다 (ratio scale) 는 표현은 불가능
 - ㅇ 온도
 - 20도와 10도의 차이는 10도
 - 그러나 20도가 10도의 두 배는 아님
 - 0도는 물이 어는 온도이지만 절대적인 "없음"의 개념은 아님
 - ο 연도
 - 2024년이 1012년의 두배는 아님
 - 두 연도 간의 간격은 계산 가능







Level of Measurement: Examples


		Scale level
1	States of the USA	nominal
2	Product rating on a scale from 1 to 5	ordinal
3	religious confession 고해목록	nominal
4	CO2 emissions in the year	metric, ratio scale
5	IQ-Score of students	metric, interval scale
6	examination grades from 1 to 5	ordinal
7	telephone numbers of respondents	nominal
8	care level of a patient	ordinal
9	Living space in m ²	metric, ratio scale
10	job satisfaction on a scale from 1 to 4	ordinal

Descriptive Statistics


- 통계적 특성 (characteristics), 차트 (chart), 그래픽 (graphics) 또는 표 (tables)를 사용하여 데이터를 설명하는 (describing) 통계적 방법 (statistical methods)
- Descriptive Statistics 방식의 구분
 - o Location parameters (위치 매개변수)
 - o Dispersion parameters (분산 매개변수)
 - o Tables
 - o Charts

Location Parameters


- Measures of central tendency (중심화 경향)
- Data distribution의 "center" 의 위치에 대한 정보
- Mean, Median, Mode



Mean



Arithmetic Mean



Data들이 반드시 양을 나타내는 숫자 로 표현되는 **metric data**이어야 함

Root Mean Square

Root Mean Square

$$ar{x}_{ extit{RMS}}\!=\sqrt{rac{x_1^2+x_2^2\!+\!\ldots\!+\!x_n^2}{n}}$$

- = RMS, Quadratic Mean
 - o 절대값의 mean 측정과 유사
 - o 그러나, RMS는 미분가능
 - 양수와 음수가 섞인 데이터들의 합보다 그 절대값,즉, 변동폭이 더 중요한 경우
- ex) 머신러닝 모델의 예측값(output)과 진실값(ground truth) 간의 RMS 오차 측정
 - ㅇ 예측값: [3, 5, 2.5, 7], 진실값: [3, 5.5, 2, 8]
 - $\circ \{(3-3)^2 + (5-5.5)^2 + (2.5-2)^2 + (7-8)^2\} / 4 = 1.5 / 4 = 0.375$

Geometric Mean

Geometric Mean

$$ar{x}_{geom} = \sqrt[n]{x_1 \cdot x_2 \cdot \ldots \cdot x_n} = \left(\prod_{i=1}^n x_i
ight)^{\frac{1}{n}}$$
 • Geometric Mean (기아평균)
 \circ n개 데이터를 모두 곱한 후,
 그 값의 n번째 root를 구함
 \circ 비율이나 성장률의 평균을 \circ

- Geometric Mean (기하평균)

 - 비율이나 성장률의 평균을 구할 때 사용


- ex) 3년 간 주식 평균 수익 율 계산
 - ㅇ 1년차: 10%, 2년차: 20%, 3년차: -10%
 - o 소수점으로 변환하면: 1.10, 1.20, 0.90
 - o 모두 곱함: 1.10 * 1.20 * 0.90 = 1.188
 - o 세제곱근 (3개 데이터이므로) = $\sqrt[3]{1.188}$ ≈ 1.058
 - 즉 (1.058 1.0) = 0.058 = 5.8 % 수익


Median

- Data를 sorting하여 순서대로 세웠을 때 중간에 오는 값
- Data가 반드시 metric data일 필요는 없으나, 순서를 정할 수 있어야 함 (Ordinal data)




Median – Odd and Even Number of Values






Mean vs Median

• Median 은 scattering에 robust함. Outlier가 median에 주는 영향이 적음



Mode (Modal Value)

- Most common value (가장 많이 출현하는 값) = Most frequent value
- Data는 구별되기만 하면 됨 (Nominal, Ordinal, Metric)



Car brand	Daimler	BMW	vw	Audi
Frequency	20	25	10	15

Frequency Table


Comparisons

	Advantages	Disadvantages	Data
Mean	Most used	Sensitive to outlier	Metric
Median	Robust against outliers	Not utilizing all the information in the data	Metric, Ordinal
Mode	Computable for Non numerical data	Not reflect the characteristics of entire data	Metric, Ordinal, Nominal

Dispersion parameter


• Describe the **scatter of values** of a sample around a location parameter

Standard deviation




Average distance of all measured values from the mean value

Range



Distance between lowest and highest value of a distribution


Interquartile range




Spectrum in which the middle 50% of the values lie. Difference between first and third quartile

Standard Deviation

- Mean deviation (root mean square) of all measured values from the mean
- Indicates the spread of a variable around its mean



std of population:




std of sample:

$$s = \sqrt{\frac{1}{n-1}} \sum_{i=1}^{n} (x_i - \bar{x})^2$$

Variance


measures the squared average distance from the mean

Variance
$$\dfrac{1}{n}\sum_{i=1}^n(x_i-ar{x})^2$$
 Standard deviation $\sqrt{\dfrac{1}{n}\sum_{i=1}^n(x_i-ar{x})^2}$



Why Divide by (n-1) in Sample Variance?

- Degree of Freedom (df)
 - o The number of ways that observed data values can vary independently
 - o data를 자유롭게 선택할 수 있는 개수
 - (#total data) (#parameters being estimated)
 - o ex) n개 data -1 (평균): 분산에서는 평균을 먼저 정해 놓고 계산
 - \circ ex) n=4 개의 수를 선택하되 그들의 평균이 m=2 이 되도록
 - *n* 1 = 3 개 수 까지는 자유롭게 선택 가능
 - 나머지 한 개는 자유롭게 선택 불가. 평균을 m=2 로 만들어야 하므로




■ 결국 X = -1 로 고정되며, df = 3 이 됩니다.

Range

$$R = x_{max} - x_{min}$$



Quartile, Interquartile Range (IQR)



Frequency Table

Car brand	Frequency	%	Valid %
VW	3	25%	27.27%
Ford	3	25%	27.27%
BMW	2	16.67%	18.18%
Opel	2	16.67%	18.18%
Daimler	1	8.33%	9.09%
Total	11	91.67%	100%
Invalid	1	8.33%	
Total	12	100%	

Contingency Table

• Frequency Table을 다른 조건 분류로 세분화









	Cake	Ice	Donut	Total
Female	4	3	6	13
Male	5	7	9	21
Total	9	10	15	34


Female and without a degree occurs 6 times in the data

	Female	Male
Without graduation	6	7
College	13	16
Bachelor	16	15
Master	8	11
Total	43	49

With umbrella

		yes	no	Total
Gender	female	5	7	12
	male	5	5	10
	Total	10	12	22


Charts





Bar chart vs. Histogram = Discrete vs. Continuous data

Scatter Plots

- visualize correlations in data
- two variables can be plotted









Boxplot

Compare and contrast two or more groups







Violin Plot

• Similar to boxplot, showing probability distribution

Response time by Time of day




Raincloud Plot



Sankey diagram

- 어떤 value들의 set에서 다른 value set으로 value의 flow를 표시
- 여러 단계의 프로세스 간의 에너지, 재료, 또는 비용의 flow를 시각화
- Flow arrow의 너비는 Flow 양에 비례

Gender	Place	Company
Female	Chicago	BMW
Female	Chicago	Ford
Male	New York	BMW
Male	New York	BMW
Female	Chicago	Ford
Female	Washington	Ford
Male	Washington	Ford
Male	Washington	Ford
Female	New York	Ford
Male	New York	GM
Female	Washington	BMW
Male	New York	GM



Python Code

- https://github.com/iklee99/StatCode
 - o 01_descriptive.py
 - packages needed: pandas numpy matplotlib seaborn scipy
 - for installing package(s): pip install package_name1 package_name2 ... (in console)
 - o seaborn Package (document): https://seaborn.pydata.org/

Free Utilities

- JASP (https://jasp-stats.org/)
 - o 무료 (Open-source)
 - Frequentist Analyses (지금 이 note들에서 다루는 방식) 가설검정: p-value 기반
 - Bayesian Analyses (확률을 주관적 신념, 사전 정보로 정의) 가설검정: 확률적 추론을 사용하여 특정 가설이 참일 확률을 계산할 수 있음. ex) Null hypothesis 가 true일 확률은 얼마인가?
 - Free textbook: "Learning Statistics with JASP"
- SOFA (https://www.sofastatistics.com/home.php)
- GNU PSPP (https://www.gnu.org/software/pspp/): Alternative to SPSS
- SCI Labs (https://www.scilab.org/software/scilab/statistics)
- Jamovi (<u>https://www.jamovi.org/</u>)
- MacAnova (https://www.stat.umn.edu/macanova/macanova.home.html)
- Devele (<u>https://develve.net/</u>)
- InVivoStat (https://invivostat.co.uk/)
- IBM SPSS (https://www.ibm.com/spss)